

GENIAL Deep Research

Note d'arbitrage finale · 28 août 2026 · release candidate premium

Validation finale du 28 août 2026

Construire un dossier commercial défendable, pas une synthèse vraisemblable. La release accepte de perdre du rappel pour préserver identité, portée et preuve.

Décision produit

Une identité non démontrée demande du contexte. Un fait dont l'extrait n'est pas retrouvé disparaît. Une recherche pauvre produit un silence borné. Une panne technique ne devient jamais un dossier partiel.

Quatre issues de dossier restent lisibles : complet dans le périmètre, partiel, clarification et données publiques insuffisantes, plus un terminal d'erreur technique distinct. Chaque fait visible garde sa preuve adjacente. Le résumé extractif exclut les versions contestées.

Le fournisseur propose, le serveur décide.

Architecture de vérité

1 · Proposition

OpenAI gpt-5.6-1una propose candidats, faits, URL et extraits via sortie structurée et Web Search.

2 · Vérification

Le serveur récupère chaque URL après contrôles anti-SSRF, DNS, redirections, durée, taille et HTML. L'extrait doit être retrouvé littéralement.

3 · Décision

Candidat unique, contexte prouvé, sujet, type, portée, qualité, temporalité et complétude sont recalculés côté serveur.

4 · Présentation

Source → Evidence → Claim → Presentation. Schéma JSON, invariants runtime et masque client ferment la chaîne.

Choix de périmètre

Le monolithe Next.js n'utilise ni base, ni compte, ni persistance de dossier. OpenAI sert une verticale unique et maîtrisée. Le probe historique OpenAI/Gemini n'était pas un benchmark métier annoté. Ajouter Gemini sans gain démontré augmenterait variabilité, coût, latence, réconciliation et modes de panne ; l'accord entre deux modèles ne vaut pas preuve indépendante. Gemini reste candidate à un benchmark ou fallback calibré, sans revendication de supériorité universelle d'OpenAI.

Décider sans mélanger

Identité · contexte · portée · complétude

Résolution et portée

resolved implique exactement un candidat directement vérifié. Le contexte n'est retenu que s'il correspond à un domaine officiel, un identifiant légal, un employeur, ou à deux signaux vérifiés parmi ville, pays, secteur et année.

Pour chaque fait, l'égalité de type ne suffit pas. Sujet, portée — personne, société, groupe, filiale ou marque —, libellé et présence de l'entité sur la page doivent converger.

Complétude et temporalité

Un dossier complet exige trois à six faits métier uniques, deux catégories, deux pages et deux familles d'éditeurs, sans contradiction, violation de portée ni manque critique. GENIAL n'obtient qu'une preuve d'identité et un fait métier, d'une même famille : le statut partial est correct.

Une année ou une date récente ne suffit jamais à produire current. Il faut une formulation actuelle explicite et une date exacte correspondant à l'observation.

Bench live préenregistré

Cas	Décision observable	Coût
GENIAL	Identité résolue, 1 preuve d'identité, 1 fait métier, 2 pages, partial.	0,0141440 USD
Thomas Martin	Aucun fait attribué ; silence sûr.	0,0455815 USD
Airbus SAS	Entité légale prouvée ; aucune métrique Airbus SE ; clarification.	0,0249935 USD
SILENCE	0 fait, 0 source ; absence documentaire distincte d'une panne.	0,0111351 USD
Holdout Google Ireland	Entité exacte isolée ; aucune donnée Google LLC ou Alphabet.	0,0246989 USD

Une seule exécution par cas, dans l'ordre gelé ; aucun rerun, aucune sélection du meilleur résultat et aucun patch nominal pour le holdout. Airbus et le holdout montrent une résolution parfois plus prudente qu'utile.

MARQUE, CONFLIT et PÉREMPTION ne sont pas revendiqués dans ce bench live historique.

CONFLIT déterministe

Deux chiffres d'affaires synthétiques en EUR conservent même entité, métrique, période et périmètre, deux chemins de page, deux empreintes de document et deux preuves, sans gagnant. Les tests serveur, client et Playwright régressent si une version, une source, une empreinte ou une dimension disparaît ; deux variantes de requête d'une même page sont refusées. Captures 1 440/390 px étiquetées ; aucun appel fournisseur et coût nul.

Attente et résultat

Le SSE expose des étapes réelles sans pourcentage fictif. Le terminal réel prime sur la dernière étape ; le focus rejoint résultat ou erreur. Onze parcours couvrent sorties, conflit, panne, clavier, mouvement réduit et 390/768/1 440 px. Aucun overflow horizontal. Scores observés : 100/100/100/100 desktop et 99/100/100/100 mobile ; seuils automatiques : 95/100/100/95.

Coût, clés et limites

Décision de livraison et suite

Coût exact

Les cinq exécutions finales préenregistrées ont coûté **0,1205530 USD** au total. Cette somme dépasse de **0,0005530 USD** l'enveloppe interne stricte de validation fixée à **0,12 USD**. Tous les coûts individuels restent inférieurs à **0,10 USD**. Les appels ont été arrêtés immédiatement après le cinquième reçu et aucun résultat n'a été sélectionné a posteriori.

Cette enveloppe cumulée était un contrôle interne, pas une exigence du brief. Aucun reçu, coût ou résultat brut n'a été modifié. La limite reste déclarée sans requalifier le résultat historique.

Protection proportionnée des clés

- Seule OPENAI_API_KEY est utilisée ; métadonnées Vercel Sensitive Preview/Production, sans valeur lue.
- Gemini et toute variable fournisseur NEXT_PUBLIC_* sont absentes.
- Secrets exclus de Git, bundle client, captures, PDF et logs ; aucune valeur ou empreinte publiée.
- store: false ; aucune persistance applicative, sans revendiquer une rétention fournisseur universellement nulle.
- WAF : 8 requêtes / 600 s / IP sur /api/research.
- Garde locale d'admission et 2 recherches simultanées ; plafond par fiche de 0,10 USD.
- Risque résiduel : consommation indirecte via l'endpoint, distincte d'une fuite. Rotation/révocation recommandée après l'évaluation.

Limites assumées

Sources

Web public accessible ; pages JavaScript, authentifiées, paywall ou non HTML souvent écartées. Aucune archive.

Couverture

Pas d'exhaustivité. Date de publication parfois absente. Sorties probabilistes.

Produit

Pas de compte, historique, export, file durable ni reprise après fermeture.

Suite

Benchmark aveugle annoté de 50–100 entités avant d'augmenter le rappel ou d'ajouter un fournisseur.

Preuves

[Application](#) · [Code](#) · [Bench live historique](#) · [CONFLIT](#) · [WAF](#)